PYTHON

DATA SCIENCE

by Kevin Perdana

PYTHON

Data Science

Data science adalah salah satu disiplin ilmu yang secara khusus mempelajari soal data terutama data kuantitatif atau data numerik. Saat ini, ilmu yang satu ini mulai menjelma menjadi suatu profesi baru di bidang teknologi yang banyak dicari oleh berbagai jenis perusahaan.

Secara umum data science adalah penggalian atau bisa juga disebut mengekstrak data agar dapat difilter serta didapatkan data yang benar untuk menghasilkan produk data yang sebenar-benarnya.

1.1 Contoh Implementasi Data Science

- Rekomendasi Barang Online Shop

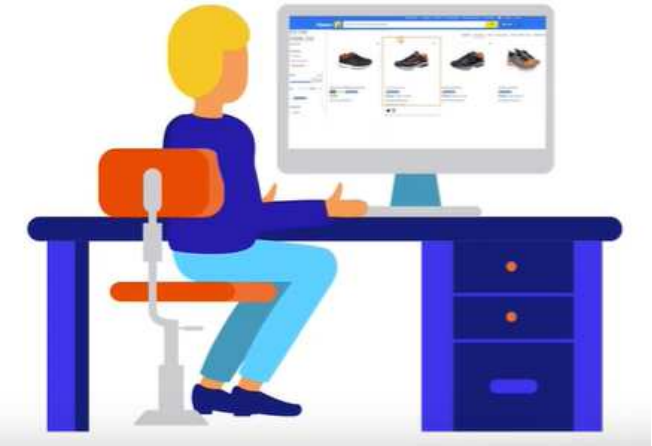

Gambar 1 Online Shop

- Prediksi Kata pada Keyboard Smartphone

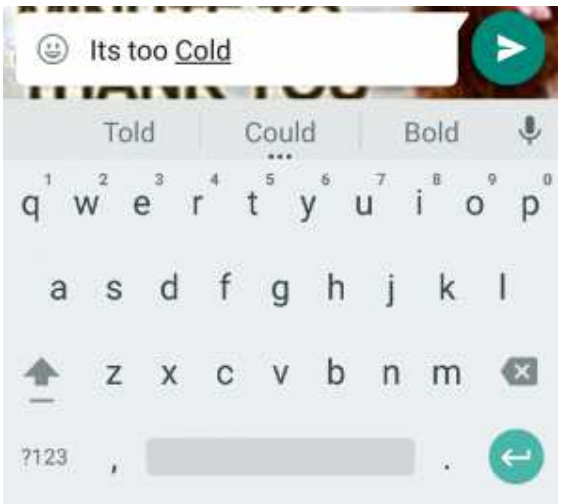

Gambar 2 Smartphone Keyboard

Kevin Perdana, ST
https://medium.com/@kevinperdana

- Rekomendasi Video Youtube, dll

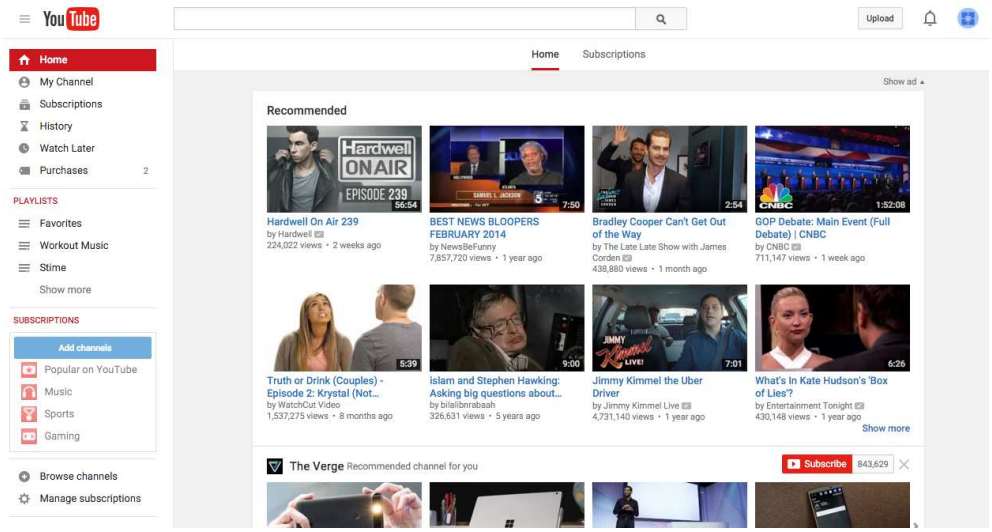

Gambar 3 Rekomendasi Video Youtube

Pandas DataFrame

2.1 Pendahuluan

Pandas berasal dari kata Python Data Analysis Library, turunan dari kata Panel Data. Mendukung data multi-dimensi yang artinya elemen-elemen pada data diakses dengan menggunakan 2 buah index. Sedangkan data satu dimensi adalah elemen pada data dapat diakses hanya dengan 1 buah index.

	Age	Location	Name
0	24	New York	John
1	13	Paris	Anna
2	53	Berlin	Peter
3	33	London	Linda

Gambar 4 Data Multi-Dimensi

2.1.1 Series

Series merupakan struktur data dasar dalam Pandas. Series adalah data satu dimensi yang dapat berisi tipe data seperti integer, string, dll. Dan mendukung tipe data sama atau campuran. Contoh series object.

1. Membuat Series

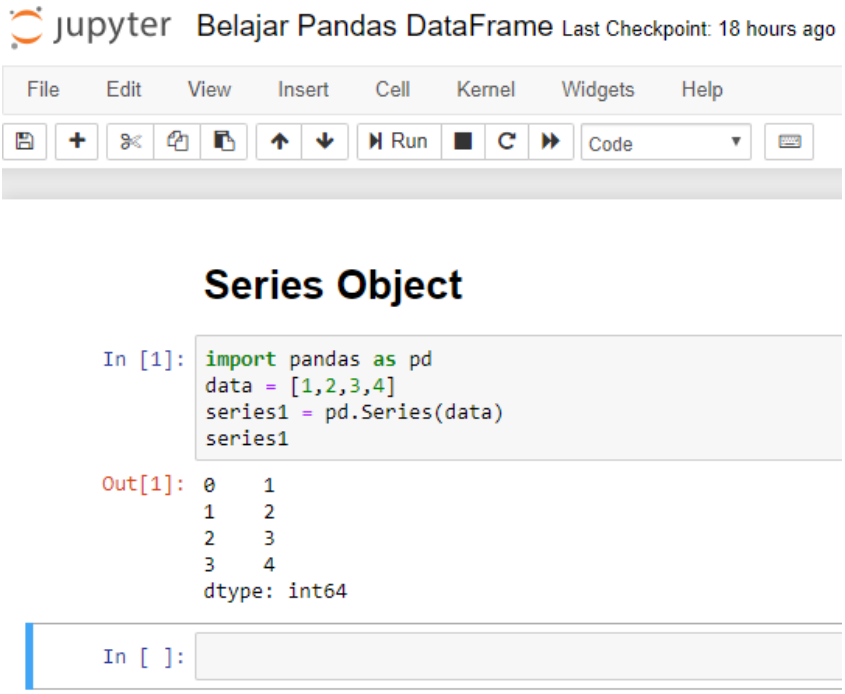

Gambar 5 Series Object

Kevin Perdana, ST
https://medium.com/@kevinperdana

2. Cek Tipe Struktur Data Series atau Bukan

```
In [2]: type(series1)
Out[2]: pandas.core.series.Series

In [ ]:
```

Gambar 6 Cek Tipe Struktur Data Series atau Bukan

3. Ubah Nama Index

Ubah Nama Index

```
In [3]: series1 = pd.Series(data, index = ['a','b','c','d'])
        series1

Out[3]: a    1
        b    2
        c    3
        d    4
        dtype: int64
```

Gambar 7 Ubah Nama Index

2.1.2 DataFrame

DataFrame merupakan array dua dimensi dengan baris dan kolom. Struktur data ini merupakan cara paling standar untuk menyimpan data. Secara sederhana, DataFrame merupakan tabel/data tabular. Setiap kolom pada DataFrame merupakan objek dari Series, dan baris terdiri dari elemen yang ada pada Series. Contoh DataFrame.

1. DataFrame Menggunakan List

DataFrame

```
In [4]: import pandas as pd
        data = [1,2,3,4]
        df = pd.DataFrame(data)
        df
```

Out[4]:

	0
0	1
1	2
2	3
3	4

Gambar 8 DataFrame Menggunakan List

Kevin Perdana, ST
https://medium.com/@kevinperdana

2. DataFrame Menggunakan Dictionary

```
In [7]: dictionary = {'buah ':['Apel','Jeruk','Lemon'],'jumlah':[10,5,12]}
        df = pd.DataFrame(dictionary)
        df
```

Out[7]:

	buah	jumlah
0	Apel	10
1	Jeruk	5
2	Lemon	12

```
In [ ]:
```

Gambar 9 DataFrame Menggunakan Dictionary

3. DataFrame Menggunakan List dengan Tipe Data Campuran

DataFrame List Tipe Data Campuran

```
In [2]: import pandas as pd
        data = [['Berti',90,85,95,90.5],
                ['Qorygore',80,85,90,86.6],
                ['Bimo',70,75,80,78.5]]
        index = [0,1,2]
        kolom = ['Nama','Tugas','UTS','UAS','Rata-Rata']
        df = pd.DataFrame(data, index, kolom)
        df
```

Out[2]:

	Nama	Tugas	UTS	UAS	Rata-Rata
0	Berti	90	85	95	90.5
1	Qorygore	80	85	90	86.6
2	Bimo	70	75	80	78.5

Gambar 10 DataFrame Menggunakan List dengan Tipe Data Campuran

Kevin Perdana, ST
https://medium.com/@kevinperdana

4. DataFrame Menggunakan List & Dictionary dengan Tipe Data Campuran

```
In [4]: # atau dengan Dictionary
        import pandas as pd
        nama = ['Berti','Qorygore','Bimo']
        tugas = [90,80,70]
        uts = [85,85,75]
        uas = [95,90,80]
        ratarata = [90.5,86.6,78.5]
        df2 = pd.DataFrame({'Nama':nama,'Tugas':tugas,'UTS':uts,'UAS':uas,'Rata-Rata':ratarata})
        df2
```

Out[4]:

	Nama	Tugas	UTS	UAS	Rata-Rata
0	Berti	90	85	95	90.5
1	Qorygore	80	85	90	86.6
2	Bimo	70	75	80	78.5

Gambar 11 DataFrame Menggunakan List & Dict dengan Tipe Data Campuran

Kevin Perdana, ST
https://medium.com/@kevinperdana

2.2 Merge, Join, & Concatenate DataFrame

Ketiga fungsi ini pengertiannya adalah operasi penggabungan. Perbedaannya adalah sebagai berikut.

2.2.1 Merge

Merge adalah operasi penggabungan antara DataFrame Objects.

1. Siapkan 2 Data

```
In [19]: # DATA PERTAMA
import pandas as pd
nama = ['Berti','Ryndes','Arin']
tugas = [95,90,75]
jurusan = ['IF','SI','KA']
df3 = pd.DataFrame({'Nama':nama,'Tugas':tugas,'Jurusan':jurusan})
df3
```

Out[19]:

	Nama	Tugas	Jurusan
0	Berti	95	IF
1	Ryndes	90	SI
2	Arin	75	KA

```
In [20]: # DATA KEDUA
nama = ['Berti','Ryndes','Rylo']
uts = [85,84,70]
jurusan = ['IF','SI','SI']
df4 = pd.DataFrame({'Nama':nama,'UTS':uts,'Jurusan':jurusan})
df4
```

Out[20]:

	Nama	UTS	Jurusan
0	Berti	85	IF
1	Ryndes	84	SI
2	Rylo	70	SI

Gambar 12 Dua DataFrame untuk di-Merge

2. Inner Merge

```
In [21]: # INNER MERGE
df3.merge(df4)
```

Out[21]:

	Nama	Tugas	Jurusan	UTS
0	Berti	95	IF	85
1	Ryndes	90	SI	84

Gambar 13 Inner Merge

Kevin Perdana, ST
https://medium.com/@kevinperdana

3. Left Merge

```
In [23]: # LEFT MERGE
         df3.merge(df4, on='Nama', how='left')
```

Out[23]:

	Nama	Tugas	Jurusan_x	UTS	Jurusan_y
0	Berti	95	IF	85.0	IF
1	Ryndes	90	SI	84.0	SI
2	Arin	75	KA	NaN	NaN

Gambar 14 Left Merge

4. Right Merge

```
In [28]: # RIGHT MERGE
         df3.merge(df4, on='Nama', how='right')
```

Out[28]:

	Nama	Tugas	Jurusan_x	UTS	Jurusan_y
0	Berti	95.0	IF	85	IF
1	Ryndes	90.0	SI	84	SI
2	Rylo	NaN	NaN	70	SI

Gambar 15 Right Merge

5. Outer Merge

```
In [29]: # OUTER MERGE
         df3.merge(df4, on='Nama', how='outer')
```

Out[29]:

	Nama	Tugas	Jurusan_x	UTS	Jurusan_y
0	Berti	95.0	IF	85.0	IF
1	Ryndes	90.0	SI	84.0	SI
2	Arin	75.0	KA	NaN	NaN
3	Rylo	NaN	NaN	70.0	SI

Gambar 16 Outer Merge

Kevin Perdana, ST
https://medium.com/@kevinperdana

2.2.2 Join

Join adalah operasi penggabungan dengan menggunakan index.

1. Siapkan 2 Data

```
In [30]: # DATA PERTAMA
nama = ['Berti','Ryndes','Arin']
tugas = [95,90,75]
jurusan = ['IF','SI','KA']
df3 = pd.DataFrame({'Nama':nama,'Tugas':tugas,'Jurusan':jurusan}, index=['L1','L2','L3'])
df3
```

Out[30]:

	Nama	Tugas	Jurusan
L1	Berti	95	IF
L2	Ryndes	90	SI
L3	Arin	75	KA

```
In [31]: # DATA KEDUA
nama = ['Berti','Ryndes','Rylo']
uts = [85,84,70]
jurusan = ['IF','SI','SI']
df4 = pd.DataFrame({'Nama B':nama,'UTS':uts,'Jurusan B':jurusan}, index=['L2','L3','L4'])
df4
```

Out[31]:

	Nama B	UTS	Jurusan B
L2	Berti	85	IF
L3	Ryndes	84	SI
L4	Rylo	70	SI

Gambar 17 Dua DataFrame untuk di-Join

2. Inner Join

```
In [33]: # INNER JOIN
df3.join(df4, how='inner')
```

Out[33]:

	Nama	Tugas	Jurusan	Nama B	UTS	Jurusan B
L2	Ryndes	90	SI	Berti	85	IF
L3	Arin	75	KA	Ryndes	84	SI

Gambar 18 Inner Join

Kevin Perdana, ST
https://medium.com/@kevinperdana

3. Left Join

```
In [34]: # LEFT JOIN
         df3.join(df4, how='left')
```

Out[34]:

	Nama	Tugas	Jurusan	Nama B	UTS	Jurusan B
L1	Berti	95	IF	NaN	NaN	NaN
L2	Ryndes	90	SI	Berti	85.0	IF
L3	Arin	75	KA	Ryndes	84.0	SI

Gambar 19 Left Join

4. Right Join

```
In [35]: # RIGHT JOIN
         df3.join(df4, how='right')
```

Out[35]:

	Nama	Tugas	Jurusan	Nama B	UTS	Jurusan B
L2	Ryndes	90.0	SI	Berti	85	IF
L3	Arin	75.0	KA	Ryndes	84	SI
L4	NaN	NaN	NaN	Rylo	70	SI

Gambar 20 Right Join

5. Outer Join

```
In [36]: # OUTER JOIN
         df3.join(df4, how='outer')
```

Out[36]:

	Nama	Tugas	Jurusan	Nama B	UTS	Jurusan B
L1	Berti	95.0	IF	NaN	NaN	NaN
L2	Ryndes	90.0	SI	Berti	85.0	IF
L3	Arin	75.0	KA	Ryndes	84.0	SI
L4	NaN	NaN	NaN	Rylo	70.0	SI

Gambar 21 Outer Join

Kevin Perdana, ST
https://medium.com/@kevinperdana

2.2.3 Concatenate

Concatenate adalah operasi penggabungan objek DataFrame secara vertical.

```
In [42]: pd.concat([df3,df4], sort='False')
```

Out[42]:

	Jurusan	Jurusan B	Nama	Nama B	Tugas	UTS
L1	IF	NaN	Berti	NaN	95.0	NaN
L2	SI	NaN	Ryndes	NaN	90.0	NaN
L3	KA	NaN	Arin	NaN	75.0	NaN
L2	NaN	IF	NaN	Berti	NaN	85.0
L3	NaN	SI	NaN	Ryndes	NaN	84.0
L4	NaN	SI	NaN	Rylo	NaN	70.0

Gambar 22 Concatenate

2.3 Pandas DataFrame - Import Data CSV

Pada tahap ini akan dibahas mengenai cara import data CSV ke dalam Panda DataFrame dan mengolah datanya.

2.3.1 Import Data CSV

```
In [3]: import pandas as pd

        # membaca dataset dan store ke dataframe
        sample = pd.read_csv("sampledataok.csv")

        # print
        sample
```

Out[3]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
0	Raditya Dika	L	34	Komedi	7000000
1	Statement Prod	L	29	Daily Vlog	120000
2	Arief Muhammad	L	28	Daily Vlog	3000000
3	Annisa Aziza	P	25	Food Travel	600000
4	Sarah Viloid	P	23	Gamer	2000000
5	MLI	L	30	Komedi	800000
6	Chandra Liow	L	26	Sketsa	3000000

Gambar 23 Import Data CSV

2.3.2 Macam - Macam Operasi

Fungsi-fungsi yang dapat dilakukan oleh Pandas DataFrame adalah sebagai berikut.

1. head()

```
In [4]: # head(), menampilkan 5 records pertama
        sample.head()
```

Out[4]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
0	Raditya Dika	L	34	Komedi	7000000
1	Statement Prod	L	29	Daily Vlog	120000
2	Arief Muhammad	L	28	Daily Vlog	3000000
3	Annisa Aziza	P	25	Food Travel	600000
4	Sarah Viloid	P	23	Gamer	2000000

```
In [5]: # menampilkan 2 records pertama
        sample.head(2)
```

Out[5]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
0	Raditya Dika	L	34	Komedi	7000000
1	Statement Prod	L	29	Daily Vlog	120000

Gambar 24 head()

2. tail()

```
In [6]: # tail(), menampilkan 5 records terakhir
        sample.tail()
```

Out[6]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
2	Arief Muhammad	L	28	Daily Vlog	3000000
3	Annisa Aziza	P	25	Food Travel	600000
4	Sarah Viloid	P	23	Gamer	2000000
5	MLI	L	30	Komedi	800000
6	Chandra Liow	L	26	Sketsa	3000000

```
In [7]: # menampilkan 3 records terakhir
        sample.tail(3)
```

Out[7]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
4	Sarah Viloid	P	23	Gamer	2000000
5	MLI	L	30	Komedi	800000
6	Chandra Liow	L	26	Sketsa	3000000

Gambar 25 tail()

Kevin Perdana, ST
https://medium.com/@kevinperdana

3. shape

```
In [8]: # menampilkan jumlah baris dan kolom pada DataFrame
        sample.shape

Out[8]: (7, 5)
```

Gambar 26 shape

4. Mean, Median, Standar Deviasi

```
In [9]: # mean adalah rata-rata
        # 2.785714e+01 artinya 2.785714 * 10^1 = 2.785714 * 10 jadi Mean-nya adalah 27.85714
        # 2.360000e+06 artinya 2.360000 * 10^6 = 2.360000 * 1000000 jadi Mean-nya adalah 2360000
        sample.mean()

Out[9]: umur          2.785714e+01
        subscriber    2.360000e+06
        dtype: float64

In [10]: # median adalah nilai tengah dari data yang telah diurut dari terkecil hingga terbesar
         # umur : 23 25 26 28 29 30 34
         sample.median()

Out[10]: umur              28.0
         subscriber    2000000.0
         dtype: float64

In [15]: # standar deviasi
         sample.std()

Out[15]: umur          3.625308e+00
         subscriber    2.346174e+06
         dtype: float64
```

Gambar 27 Mean, Median, Standar Deviasi

Kevin Perdana, ST
https://medium.com/@kevinperdana

5. Max, Min, Count

```
In [16]: # max untuk mencari nilai tertinggi
         sample.max()

Out[16]: nama_youtuber    Statement Prod
         jenis_kelamin                 P
         umur                         34
         kategori                 Sketsa
         subscriber              7000000
         dtype: object

In [17]: # min untuk mencari nilai terendah
         sample.min()

Out[17]: nama_youtuber    Annisa Aziza
         jenis_kelamin                L
         umur                        23
         kategori             Daily Vlog
         subscriber               120000
         dtype: object

In [18]: # jumlah non null record pada setiap kolom
         sample.count()

Out[18]: nama_youtuber    7
         jenis_kelamin    7
         umur             7
         kategori         7
         subscriber       7
         dtype: int64
```

Gambar 28 Max, Min, Count

6. describe()

```
In [19]: # ringkasan statistik data
         sample.describe()
```

Out[19]:

	umur	subscriber
count	7.000000	7.000000e+00
mean	27.857143	2.360000e+06
std	3.625308	2.346174e+06
min	23.000000	1.200000e+05
25%	25.500000	7.000000e+05
50%	28.000000	2.000000e+06
75%	29.500000	3.000000e+06
max	34.000000	7.000000e+06

Gambar 29 describe()

Kevin Perdana, ST
https://medium.com/@kevinperdana

7. Rename dan Drop Kolom

```
In [20]: # rename kolom
sample = sample.rename(columns={'nama_youtuber':'Youtuber'})
sample
```

Out[20]:

	Youtuber	jenis_kelamin	umur	kategori	subscriber
0	Raditya Dika	L	34	Komedi	7000000
1	Statement Prod	L	29	Daily Vlog	120000
2	Arief Muhammad	L	28	Daily Vlog	3000000
3	Annisa Aziza	P	25	Food Travel	600000
4	Sarah Viloid	P	23	Gamer	2000000
5	MLI	L	30	Komedi	800000
6	Chandra Liow	L	26	Sketsa	3000000

```
In [21]: # drop atau menghilangkan kolom
sample = sample.drop(columns=['jenis_kelamin'])
sample
```

Out[21]:

	Youtuber	umur	kategori	subscriber
0	Raditya Dika	34	Komedi	7000000
1	Statement Prod	29	Daily Vlog	120000
2	Arief Muhammad	28	Daily Vlog	3000000
3	Annisa Aziza	25	Food Travel	600000
4	Sarah Viloid	23	Gamer	2000000
5	MLI	30	Komedi	800000
6	Chandra Liow	26	Sketsa	3000000

Gambar 30 Rename dan Drop Kolom

Kevin Perdana, ST
https://medium.com/@kevinperdana

8. iloc

```
In [9]: # menampilkan record 1 kolom (umur yang berada di indeks ke-2)
        sample.iloc[:,2]
```

```
Out[9]: 0    34
        1    29
        2    28
        3    25
        4    23
        5    30
        6    26
        Name: umur, dtype: int64
```

```
In [11]: # menampilkan 3 record pertama dari 1 kolom (umur)
         sample.iloc[0:3,2]
```

```
Out[11]: 0    34
         1    29
         2    28
         Name: umur, dtype: int64
```

```
In [12]: # tampilkan kembali semua baris dan kolom
         sample.iloc[:,:]
```

Out[12]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
0	Raditya Dika	L	34	Komedi	7000000
1	Statement Prod	L	29	Daily Vlog	120000
2	Arief Muhammad	L	28	Daily Vlog	3000000
3	Annisa Aziza	P	25	Food Travel	600000
4	Sarah Viloid	P	23	Gamer	2000000
5	MLI	L	30	Komedi	800000
6	Chandra Liow	L	26	Sketsa	3000000

```
In [16]: # menampilkan data dari record ke-3 dan kolom ke-2
         sample.iloc[3:,2:]
```

Out[16]:

	umur	kategori	subscriber
3	25	Food Travel	600000
4	23	Gamer	2000000
5	30	Komedi	800000
6	26	Sketsa	3000000

Gambar 31 iloc

Kevin Perdana, ST
https://medium.com/@kevinperdana

9. loc

```
In [19]: # menampilkan record 1 kolom, dengan menulis nama kolomnya("nama_youtuber")
         sample.loc[:,"nama_youtuber"]

Out[19]: 0      Raditya Dika
         1    Statement Prod
         2    Arief Muhammad
         3      Annisa Aziza
         4      Sarah Viloid
         5               MLI
         6      Chandra Liow
         Name: nama_youtuber, dtype: object

In [23]: # menampilkan record dari indeks ke-0 sampai ke-3 dari kolom "nama_youtuber"
         sample.loc[0:3,"nama_youtuber"]

Out[23]: 0      Raditya Dika
         1    Statement Prod
         2    Arief Muhammad
         3      Annisa Aziza
         Name: nama_youtuber, dtype: object

In [24]: # menampilkan record sampai indeks ke-3 dari kolom nama_youtuber sampai jenis_kelamin
         sample.loc[:3,"nama_youtuber":"jenis_kelamin"]
```

Out[24]:

	nama_youtuber	jenis_kelamin
0	Raditya Dika	L
1	Statement Prod	L
2	Arief Muhammad	L
3	Annisa Aziza	P

Gambar 32 loc

10. Mengisi Nilai Sama Untuk 1 Kolom

```
In [25]: # mengisi nilai 1 untuk kolom "subscriber"
         sample['subscriber']=1
         sample
```

Out[25]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
0	Raditya Dika	L	34	Komedi	1
1	Statement Prod	L	29	Daily Vlog	1
2	Arief Muhammad	L	28	Daily Vlog	1
3	Annisa Aziza	P	25	Food Travel	1
4	Sarah Viloid	P	23	Gamer	1
5	MLI	L	30	Komedi	1
6	Chandra Liow	L	26	Sketsa	1

Gambar 33 Mengisi Nilai Sama Untuk 1 Kolom

Kevin Perdana, ST
https://medium.com/@kevinperdana

11. Sorting

```
In [31]: # sorting berdasarkan ascending dari kolom "kategori"
         sample.sort_values(by='kategori')
```

Out[31]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
1	Statement Prod	L	29	Daily Vlog	1
2	Arief Muhammad	L	28	Daily Vlog	1
3	Annisa Aziza	P	25	Food Travel	1
4	Sarah Viloid	P	23	Gamer	1
0	Raditya Dika	L	34	Komedi	1
5	MLI	L	30	Komedi	1
6	Chandra Liow	L	26	Sketsa	1

```
In [32]: # sorting berdasarkan descending dari kolom "kategori"
         sample.sort_values(by='kategori', ascending=False)
```

Out[32]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
6	Chandra Liow	L	26	Sketsa	1
0	Raditya Dika	L	34	Komedi	1
5	MLI	L	30	Komedi	1
4	Sarah Viloid	P	23	Gamer	1
3	Annisa Aziza	P	25	Food Travel	1
1	Statement Prod	L	29	Daily Vlog	1
2	Arief Muhammad	L	28	Daily Vlog	1

Gambar 34 Sorting

12. Filter

```
In [35]: # filter record yang "umurnya" lebih dari 28 dan akan menampilkan status True atau False
         sample['umur'] > 28
```

Out[35]:

```
0     True
1     True
2    False
3    False
4    False
5     True
6    False
Name: umur, dtype: bool
```

```
In [36]: # filter, kemudian tampilkan record-nya
         filter1 = sample['umur'] > 28
         filterbaru = sample[filter1]
         filterbaru
```

Out[36]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
0	Raditya Dika	L	34	Komedi	1
1	Statement Prod	L	29	Daily Vlog	1
5	MLI	L	30	Komedi	1

```
In [55]: # filter dengan 2 parameter (berdasarkan yang umurnya 27 dan kategori Daily Vlog)
         filter2 = (sample['umur'] > 27) & (sample['kategori'] == 'Daily Vlog')
         filterbaru2 = sample[filter2]
         filterbaru2
```

Out[55]:

	nama_youtuber	jenis_kelamin	umur	kategori	subscriber
1	Statement Prod	L	29	Daily Vlog	120000
2	Arief Muhammad	L	28	Daily Vlog	3000000

Gambar 35 Filter

Kevin Perdana, ST
https://medium.com/@kevinperdana